UNIVERSIDADE EVANGÉLICA DE GOIÁS – UniEVANGÉLICA

CURSO DE ENGENHARIA DE SOFTWARE | DISCIPLINA: INTELIGÊNCIA ARTIFICIAL

TEMPLATE DO TRABALHO – ETAPA TEÓRICA E PROJETO

Professor(a): Lucas Marcos Turma: A

Semanas 14, 15 e 16 | Trabalho em grupos de até 2 acadêmicos

VALOR TOTAL: 25 PONTOS

IDENTIFICAÇÃO DO GRUPO

Integrante 1: Arthur Victor Rodrigues - 2310579

Integrante 2: Sergio Cavalcante - 2321154

Tema sorteado: 17 - Identificação de perfis de consumidores

Data de entrega: 05/11/2026

ORIENTAÇÕES GERAIS

Este modelo deverá ser utilizado pelo grupo para organizar a pesquisa teórica e registrar o planejamento do projeto de Inteligência Artificial. Na Semana 14, o grupo deverá preencher e entregar a parte teórica. Nas Semanas 15 e 16, deverá complementar o documento com a implementação, os testes, os resultados e a conclusão.

Escreva com suas próprias palavras, utilize fontes confiáveis e cite as referências consultadas. Não basta copiar definições: explique os conceitos e relacione-os ao problema escolhido.

1. TÍTULO DO PROJETO

Informe um título claro e relacionado ao problema que será resolvido.

Resposta: Identificação de perfis de consumidores usando K-means

2. INTRODUÇÃO

Apresente o contexto do problema, sua relevância e a relação com Inteligência Artificial. Explique por que o problema merece ser estudado.

Toda loja tem clientes bem diferentes entre si. Tem aquele cliente que aparece quase toda semana, tem o que compra pouco mas gasta bastante quando vem, e tem o que comprou uma vez e não voltou mais. Quando a empresa olha só para o total vendido no mês, essas diferenças acabam ficando escondidas.

A ideia do nosso projeto é usar Inteligência Artificial para separar os clientes em grupos de acordo com o jeito que eles compram. Assim a empresa consegue entender melhor quem são seus clientes e pensar em ações diferentes para cada grupo. Como não tínhamos acesso a dados reais de uma loja, montamos uma base fictícia para mostrar o processo todo, desde a preparação dos dados até a análise dos grupos.

3. DESCRIÇÃO DO PROBLEMA

Descreva a situação que o projeto pretende resolver. Informe quem é afetado, quais dados podem ser utilizados e qual resultado o modelo deverá produzir.

O problema é dividir os consumidores em grupos sem ter nenhuma classificação pronta, ou seja, ninguém diz antes qual é o "tipo" de cada cliente. Consideramos um cenário simulado com as compras dos últimos 180 dias e usamos três informações de cada cliente: quantos dias faz desde a última compra (recência), quantas compras ele fez no período (frequência) e quanto ele gasta em média por compra (ticket médio).

Quem se beneficia é principalmente a equipe comercial e de marketing, que poderia usar os grupos para planejar campanhas. A saída do modelo é o grupo de cada cliente, junto com uma descrição de como é o comportamento médio de cada grupo.

4. JUSTIFICATIVA

Explique por que a aplicação escolhida é relevante e por que técnicas de Inteligência Artificial podem contribuir para a solução.

Com poucos clientes dá para analisar um por um, mas quando a base cresce isso fica inviável. Um algoritmo de agrupamento consegue resumir milhares de registros em poucos perfis, o que facilita bastante a tomada de decisão. Vale lembrar que o algoritmo não explica o motivo de uma pessoa comprar mais ou menos, e também não garante que as vendas vão aumentar. Ele é uma ferramenta de apoio, e a interpretação final continua sendo das pessoas.

5. OBJETIVO GERAL E OBJETIVOS ESPECÍFICOS

Escreva um objetivo geral e de 3 a 5 objetivos específicos, usando verbos como analisar, preparar, implementar, avaliar e comparar.

Objetivo geral: aplicar o algoritmo K-means em dados de compras simulados para identificar e interpretar grupos de consumidores com comportamento parecido.

Objetivos específicos:

- Preparar a base de dados, tratando registros duplicados e valores ausentes;
- Selecionar e padronizar os atributos ligados ao comportamento de compra;
- Implementar o K-means e comparar diferentes quantidades de grupos;
- Avaliar se os grupos ficaram bem separados e se o resultado se mantém estável;
- Visualizar os resultados e interpretar os perfis encontrados.

6. FUNDAMENTAÇÃO TEÓRICA

Explique os conceitos de Inteligência Artificial e Aprendizado de Máquina necessários ao projeto. Apresente o algoritmo principal sorteado: SVM para classificação, SVM para regressão ou Redes Neurais Artificiais. Descreva seu funcionamento, características, vantagens, limitações e situações de uso.

A Inteligência Artificial é a área da computação que busca criar sistemas capazes de fazer tarefas que normalmente precisariam de raciocínio humano, como reconhecer padrões e tomar decisões (RUSSELL; NORVIG, 2022). Dentro dela está o Aprendizado de Máquina, em que o computador aprende padrões a partir dos dados em vez de seguir regras programadas manualmente.

O aprendizado de máquina pode ser supervisionado ou não supervisionado. No supervisionado, cada exemplo já vem com a resposta certa (rótulo), como acontece na classificação e na regressão, onde entram técnicas como SVM e Redes Neurais. No não supervisionado não existe rótulo, e o objetivo é descobrir uma estrutura nos próprios dados. O nosso projeto se encaixa nesse segundo caso, porque não existe uma resposta correta definida para cada cliente. A técnica usada é o agrupamento (clustering), que junta registros parecidos de acordo com os atributos escolhidos (SCIKIT-LEARN, s.d., Clustering).

O K-means foi proposto por MacQueen (1967) e funciona assim: primeiro escolhemos quantos grupos queremos (o valor de k) e o algoritmo posiciona k pontos centrais, chamados centroides. Depois cada cliente é ligado ao centroide mais próximo. Em seguida, cada centroide é recalculado pela média dos clientes do seu grupo. Esses passos se repetem até os centroides praticamente pararem de mudar. O que o algoritmo tenta fazer é diminuir a soma das distâncias ao quadrado entre cada cliente e o centro do seu grupo, valor que é chamado de inércia (SCIKIT-LEARN, s.d., KMeans).

As vantagens do K-means são que ele é simples, rápido e fácil de interpretar. Por outro lado, ele tem algumas limitações: é preciso definir o k antes, o resultado depende da escala dos dados e da posição inicial dos centroides, ele é sensível a valores extremos e funciona melhor quando os grupos têm formato mais "arredondado".

Para escolher o k usamos duas medidas. A primeira é a inércia, que sempre diminui quando aumentamos o k; por isso olhamos o ponto em que ela para de cair muito, o chamado método do cotovelo. A segunda é o coeficiente de silhueta, que compara o quanto cada ponto está perto do seu próprio grupo e o quanto está longe do grupo vizinho. Ele vai de -1 a 1, e quanto mais perto de 1, melhor o ponto está encaixado no grupo (ROUSSEEUW, 1987).

Também é importante padronizar os dados antes de usar o K-means, porque ele trabalha com distâncias. Sem isso, o ticket médio, que está na casa das centenas de reais, pesaria muito mais do que a frequência, que fica entre 1 e 25. Por isso usamos a padronização z = (x - média) / desvio padrão, que deixa cada atributo com média perto de 0 e desvio padrão perto de 1 (SCIKIT-LEARN, s.d., StandardScaler).

7. ALGORITMO E JUSTIFICATIVA DA ESCOLHA

Explique como o algoritmo será aplicado ao problema. Para SVM, esclareça se a tarefa é classificação ou regressão. Para Redes Neurais, descreva a ideia de camadas, neurônios, pesos, treinamento e previsão, conforme a complexidade do projeto.

Escolhemos o K-means, que é uma das técnicas indicadas no próprio enunciado do tema 17 (a outra opção era a rede neural do tipo SOM). Sabemos que o K-means não é SVM nem Rede Neural, que são as técnicas mais trabalhadas no modelo geral do trabalho, mas seguimos o que o tema sorteado pedia. Optamos por ele porque é mais fácil de explicar e de mostrar como os grupos se formam. Aqui a tarefa é de agrupamento, não de classificação nem de regressão.

Na prática, padronizamos os três atributos e rodamos o K-means com k variando de 2 a 6. Usamos a inicialização k-means++, 10 inicializações diferentes (n_init = 10) e semente fixa (random_state = 42) para o resultado sempre sair igual. Para cada k anotamos a inércia e a silhueta e escolhemos o melhor. Depois disso, cada cliente recebe o grupo do centroide mais próximo, e convertemos os centroides de volta para as unidades originais (dias, quantidade de compras e reais) para conseguir descrever cada perfil.

8. BASE DE DADOS E VARIÁVEIS

Indique a base de dados que pretende utilizar, sua origem, quantidade aproximada de registros, atributos e variável-alvo. Se ainda não tiver escolhido a base, descreva os dados necessários e onde pretende obtê-los.

Como não tínhamos dados reais, geramos a base em Python usando a biblioteca NumPy, com semente 42 para dar sempre o mesmo resultado. São 300 clientes fictícios, com as compras já resumidas em um período de 180 dias. Para criar a base usamos três comportamentos diferentes, com 100 clientes cada, mas essa informação não foi passada para o algoritmo. Também colocamos de propósito alguns registros duplicados e alguns valores em branco, para poder mostrar a etapa de limpeza. Sabemos que, por ser uma base montada desse jeito, os padrões ficam mais fáceis de achar do que em dados reais.

Campo	Significado	Uso
cliente_id	Código fictício do consumidor	Só identificação
recencia_dias	Dias desde a última compra	Entrada
frequencia_compras	Número de compras em 180 dias	Entrada
ticket_medio_reais	Valor médio de cada compra em reais	Entrada

Não existe variável-alvo, já que é um problema não supervisionado. O grupo de cada cliente só aparece depois que o modelo é treinado. O cliente_id não entra no cálculo. Também decidimos não usar o gasto total, porque ele é basicamente a frequência multiplicada pelo ticket médio, então ia repetir informação.

9. METODOLOGIA PROPOSTA

Descreva as etapas planejadas: obtenção dos dados, análise, limpeza, pré-processamento, divisão entre treino e teste, treinamento, avaliação e interpretação dos resultados.

Os passos que seguimos foram: gerar os dados, verificar a qualidade da base, remover os duplicados, preencher os valores em branco com a mediana, separar os três atributos e padronizá-los. Depois testamos o K-means com k de 2 a 6 e escolhemos o k com a maior silhueta, usando também a curva da inércia para confirmar. Por fim, analisamos os grupos com os valores nas unidades originais, para fazer sentido do ponto de vista comercial.

Não fizemos divisão entre treino e teste. Como não existe rótulo, não tem uma resposta certa para comparar com o que o modelo previu, então usamos todos os 300 registros e avaliamos o resultado com métricas internas. Numa aplicação real, o ideal seria testar o modelo depois com dados de um período diferente.

10. FERRAMENTAS E TECNOLOGIAS

Informe as ferramentas previstas, como Python, Google Colab/Jupyter, Pandas, NumPy, Scikit-learn e Matplotlib. Explique brevemente para que serão utilizadas.

Usamos Python como linguagem principal. O NumPy foi usado para gerar a base simulada, o Pandas para organizar e tratar os dados, o Scikit-learn para a padronização, o K-means e as métricas, e o Matplotlib para fazer os gráficos. O código foi feito em notebook e pode ser aberto no Google Colab ou no Jupyter. Também deixamos uma versão em arquivo .py e um arquivo requirements.txt com as bibliotecas usadas.

11. RESULTADOS ESPERADOS

Descreva o que se espera que o modelo consiga fazer e como será possível verificar se a solução funcionou.

Esperávamos encontrar grupos que desse para explicar, com diferenças claras de recência, frequência e ticket médio entre eles. Para considerar que a solução funcionou, definimos que o código precisava rodar sem erro, a limpeza precisava ser verificável, a silhueta precisava indicar uma separação razoável e os perfis precisavam fazer sentido. Como os dados são fictícios, não dá para provar ganho financeiro.

12. ASPECTOS ÉTICOS E LIMITAÇÕES

Aponte possíveis limitações dos dados e do modelo, riscos de erro, vieses e cuidados com privacidade. Não utilize dados pessoais identificáveis.

A base não tem nome, CPF, telefone nem nenhuma informação de pessoas reais. Se fosse aplicado numa empresa de verdade, seria importante usar só os dados necessários, controlar quem tem acesso e tomar cuidado para não expor os clientes. Também é importante lembrar que os grupos mostram como a pessoa compra, e não quem ela é, quanto ela ganha ou quanto ela "vale". Um cliente que compra menos não deve ser tratado de forma pior por causa disso.

Sobre as limitações: a base é pequena e simulada, e decisões como preencher os valores em branco pela mediana e escolher esses três atributos influenciam o resultado. O K-means também tem dificuldade quando os grupos têm formatos ou densidades muito diferentes. Além disso, uma silhueta boa não garante que a divisão vai ser útil comercialmente. Para isso seria preciso testar com dados reais e acompanhar os clientes ao longo do tempo.

13. REFERÊNCIAS

Liste livros, artigos, documentação e páginas consultadas. Utilize referências que realmente foram lidas e informe autor ou instituição, título, ano (quando disponível) e endereço eletrônico e data de acesso, se aplicável.

MACQUEEN, J. Some methods for classification and analysis of multivariate observations. In: BERKELEY SYMPOSIUM ON MATHEMATICAL STATISTICS AND PROBABILITY, 5., 1967, Berkeley. Proceedings [...]. Berkeley: University of California Press, 1967. v. 1, p. 281-297.

ROUSSEEUW, P. J. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. Journal of Computational and Applied Mathematics, v. 20, p. 53-65, 1987.

RUSSELL, S.; NORVIG, P. Inteligência artificial: uma abordagem moderna. 4. ed. Rio de Janeiro: GEN LTC, 2022.

SCIKIT-LEARN. Clustering. Documentação on-line, s.d. Disponível em: https://scikit-learn.org/stable/modules/clustering.html. Acesso em: 5 nov. 2026.

SCIKIT-LEARN. KMeans. Documentação on-line, s.d. Disponível em: https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html. Acesso em: 5 nov. 2026.

SCIKIT-LEARN. Selecting the number of clusters with silhouette analysis on KMeans clustering. Documentação on-line, s.d. Disponível em: https://scikit-learn.org/stable/auto_examples/cluster/plot_kmeans_silhouette_analysis.html. Acesso em: 5 nov. 2026.

SCIKIT-LEARN. StandardScaler. Documentação on-line, s.d. Disponível em: https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html. Acesso em: 5 nov. 2026.

PARTE PRÁTICA – COMPLEMENTAÇÃO NAS SEMANAS 15 E 16

Preencher após a implementação. Esta parte integra a entrega final do projeto.

14. PREPARAÇÃO DOS DADOS

Descreva os tratamentos realizados, atributos utilizados e como os dados foram separados para treinamento e teste.

A base foi gerada pelo próprio notebook e salva no arquivo dados/clientes_simulados.csv. Ela saiu com 306 linhas, porque colocamos 6 registros duplicados de propósito, além de 15 valores em branco (5 na recência, 4 na frequência e 6 no ticket médio).

Primeiro removemos as linhas duplicadas com o drop_duplicates, e a base ficou com os 300 clientes. Depois preenchemos os valores em branco com a mediana de cada coluna (48 dias, 4 compras e R$ 113,70). Escolhemos a mediana em vez da média porque ela é menos afetada por valores muito altos ou muito baixos.

Usamos três atributos: recencia_dias, frequencia_compras e ticket_medio_reais. O cliente_id ficou de fora do cálculo. A coluna com o comportamento usado para gerar cada cliente (perfil_gerador) foi guardada só para conferir o resultado no final e não foi usada no treinamento. Depois disso padronizamos os três atributos com o StandardScaler.

Não separamos treino e teste, pelo motivo já explicado na metodologia: como não há rótulo, usamos os 300 registros no ajuste e avaliamos com silhueta, inércia e estabilidade. Na análise exploratória percebemos que recência e frequência têm correlação negativa (-0,65), ou seja, quem compra mais vezes normalmente comprou há menos tempo, o que faz sentido.

15. IMPLEMENTAÇÃO DO MODELO

Explique as principais etapas do código e os parâmetros relevantes. Anexe ou indique o notebook/código-fonte executável.

Todo o código está no notebook perfis_consumidores_kmeans.ipynb, e o mesmo código está no arquivo perfis_consumidores_kmeans.py. O notebook roda do começo ao fim no Google Colab sem precisar enviar nenhum arquivo, porque ele mesmo gera a base, os gráficos e as tabelas.

A ordem do código é: gerar e carregar a base, verificar duplicados e valores em branco, fazer a limpeza, a análise exploratória e a padronização. Depois vem um laço que testa o K-means com k de 2 a 6 e guarda a inércia e a silhueta de cada um, e o código escolhe o k com maior silhueta. Com o k definido, treinamos o modelo final, colocamos o grupo de cada cliente na tabela e convertemos os centroides de volta para as unidades originais usando o inverse_transform.

No final ainda fizemos um teste de estabilidade, rodando o modelo com 10 sementes diferentes, geramos os gráficos (dispersão e PCA em 2D) e testamos o modelo com três clientes novos usando o modelo.predict.

Os parâmetros principais foram: n_clusters = 3 (escolhido pela silhueta); init = "k-means++", que espalha melhor os centroides iniciais; n_init = 10, que roda o algoritmo 10 vezes e fica com o melhor resultado; e random_state = 42, para dar sempre o mesmo resultado.

16. TESTES E MÉTRICAS

Informe os testes realizados. Para classificação, considere matriz de confusão, acurácia, precisão, recall e F1-score. Para regressão, considere MAE, MSE ou RMSE. Escolha métricas adequadas ao problema.

Como o nosso problema é de agrupamento, as métricas de classificação (matriz de confusão, acurácia, precisão) e de regressão (MAE, RMSE) não se aplicam aqui. Por isso usamos métricas próprias para clustering. A tabela mostra a inércia e a silhueta para cada valor de k testado:

k	Inércia	Silhueta média
2	495,2	0,464
3	163,6	0,650
4	126,2	0,555
5	96,2	0,488
6	84,0	0,492

A maior silhueta foi com k = 3 (0,650), e os três grupos ficaram com silhueta parecida, em torno de 0,65. A inércia caiu bastante de k = 2 para k = 3 (de 495,2 para 163,6) e depois passou a cair pouco, o que confirma o cotovelo em k = 3.

Para testar a estabilidade, rodamos o modelo de novo com 10 sementes diferentes e comparamos os grupos com o modelo final usando o Índice de Rand Ajustado (ARI), que vale 1 quando os grupos são iguais. A média foi 0,996 e o menor valor foi 0,990, então os grupos praticamente não mudam.

Como a base é simulada, também deu para comparar os grupos encontrados com os comportamentos usados para gerar os dados: 298 dos 300 clientes caíram no grupo esperado (ARI de 0,980). Por último, testamos o modelo com três clientes novos inventados, e cada um foi colocado no perfil que esperávamos.

17. RESULTADOS E DISCUSSÃO

Apresente tabelas, gráficos ou exemplos de previsões. Interprete os resultados, indique acertos, erros e limitações.

O modelo encontrou três grupos bem diferentes entre si. Na tabela estão as medianas de cada grupo:

Perfil	Clientes	Recência (dias)	Compras (180 d)	Ticket médio (R$)
Frequentes	102	12	14	113,70
Alto valor ocasional	98	50	3	388,00
Inativos / em risco	100	117	2	54,10

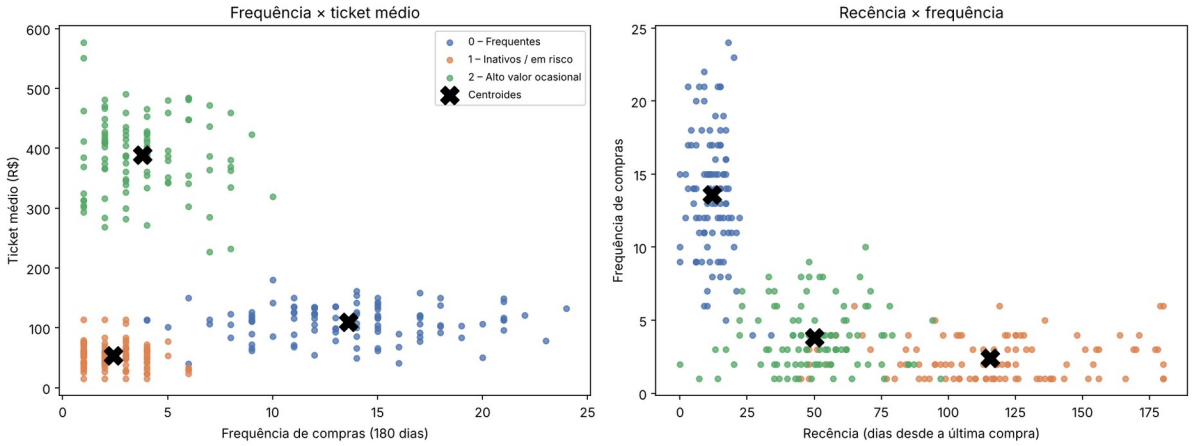


Figura 1 - Grupos encontrados e centroides (X) nas unidades originais.

Demos um nome para cada grupo de acordo com as características dele. Os Frequentes compram muitas vezes, compraram há pouco tempo e gastam um valor médio, e para eles faria sentido pensar em ações de fidelização. O grupo Alto valor ocasional compra pouco, mas gasta bem mais por compra, então a ideia seria tentar fazer esses clientes voltarem com mais frequência. Já os Inativos estão há bastante tempo sem comprar, compraram pouco e gastaram pouco, e seriam o público de uma campanha de reativação.

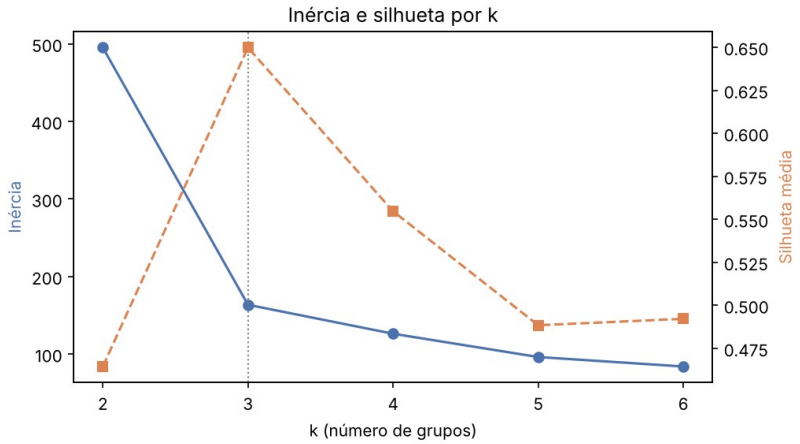


Figura 2 - Inércia e silhueta para k de 2 a 6.

Os dois clientes que ficaram fora do grupo esperado chamaram nossa atenção. Os dois eram de alto valor, mas estavam com o ticket médio em branco. Quando preenchemos com a mediana (R$ 113,70), o ticket deles ficou parecido com o do grupo Frequentes, e o modelo os colocou lá. Isso mostrou para a gente que a forma de tratar os dados faltantes pode mudar o resultado.

Também precisamos admitir que a separação ficou bem clara (silhueta de 0,65) em boa parte porque nós mesmos criamos a base com três padrões bem definidos. Com dados reais, os grupos provavelmente ficariam mais misturados e a silhueta seria menor. E os nomes dos perfis foram dados por nós olhando os centroides, o algoritmo só devolve o número do grupo.

18. CONCLUSÃO

Retome o objetivo, informe se foi alcançado, destaque aprendizados e proponha melhorias futuras.

Consideramos que o objetivo do trabalho foi alcançado. O K-means separou os 300 clientes em três perfis que dá para explicar (Frequentes, Alto valor ocasional e Inativos), com silhueta de 0,650, resultado estável entre execuções e 298 de 300 clientes no grupo esperado.

Com o trabalho aprendemos na prática por que é importante padronizar os dados quando o algoritmo usa distância, como avaliar um modelo quando não existe rótulo, e que até uma decisão simples na limpeza dos dados pode mudar o resultado. Como melhorias futuras, seria interessante testar com dados reais de vendas, comparar o K-means com a rede SOM (a outra opção do tema) e com o DBSCAN, testar outro jeito de preencher os valores em branco (por exemplo, com KNN) e rodar de novo com dados de outro período para ver se os grupos mudam.

19. CHECKLIST DA ENTREGA FINAL

☒ Documento preenchido com as partes teórica e prática.

☒ Referências bibliográficas identificadas.

☒ Código-fonte ou notebook executável.

☒ Base de dados ou link de acesso à fonte dos dados.

☒ Resultados e métricas apresentados e interpretados.

☒ Slides ou material de apoio para apresentação.

☐ Participação dos dois integrantes na apresentação.

20. CRITÉRIOS DE AVALIAÇÃO – 25 PONTOS

Critério	O que será avaliado	Pontuação
Fundamentação teórica	Clareza e correção dos conceitos de IA e do algoritmo relacionado ao tema.	0–5
Análise do problema e metodologia	Definição do problema, justificativa, objetivos, dados e planejamento coerente.	0–4
Implementação prática	Código funcional, preparação dos dados e aplicação correta do algoritmo.	0–7
Testes e análise dos resultados	Uso adequado de métricas, interpretação dos resultados e reconhecimento de limitações.	0–4
Apresentação e domínio	Organização, clareza, demonstração prática e participação dos integrantes.	0–3
Organização e referências	Qualidade do documento, estrutura, escrita e referências utilizadas.	0–2
TOTAL		25 pontos

Composição da avaliação: o valor de 25 pontos considera o processo completo, incluindo a pesquisa teórica, o desenvolvimento prático, a análise dos resultados e a apresentação final. A entrega parcial da Semana 14 será acompanhada pelo professor e comporá a avaliação do trabalho.

Nota atribuída: _____ / 25 pontos

Observações do professor: _____

_____